DESIGN DOCUMENT / MVP

AsigParse OCR

Din documente românești în date verificate, gata pentru ofertarea de asigurări.

Versiunea 1.0 • Concept demonstrabil • Piața: România

Decizia de produs

Produsul NU este „încă un OCR”. Este un flux de captură, extragere, validare umană și export JSON care reduce introducerea manuală a datelor în ofertarea RCA/CASCO.

01 Rezumat executiv

AsigParse OCR primește fotografia unei cărți de identitate românești (modelul clasic, pentru demonstrație) și a unui certificat de înmatriculare auto românesc. Extrage câmpurile relevante, aplică verificări deterministe, evidențiază valorile incerte, permite corectarea lor și generează un JSON versionat, adaptabil la sistemul de ofertare sau CRM.

Beneficiar principal: intermediarul / operatorul care preia documente pentru o ofertă auto. Utilizator secundar: echipa de integrare care consumă datele structurate prin API. Valoarea de business: mai puține reintroduceri de date, mai puține erori și timp mai scurt până la pregătirea ofertei.

02 Evaluare critică a ideii

Ce este atractiv	Ce poate eșua	Decizia pentru MVP
Necesitate reală: transcriere repetitivă	OCR simplu = funcție comoditizată	Demo „document → revizuire → prefill”, nu doar text → JSON
Date în formate relativ stabile	Fotografiile reale sunt neuniforme	Mesaje de calitate + intervenție umană
Integrare posibilă cu multiple sisteme	Câmpurile cerute variază per asigurător	Schemă internă neutră + adaptor de export

03 Definiția succesului

La finalul demonstrației, utilizatorul încarcă 2 documente de test, vede în interfață câmpurile extrase și cele problematice, corectează cel puțin o valoare, apoi descarcă JSON-ul final sau îl transmite către un formular demonstrativ de ofertare. Fără emitere de poliță și fără acces la sisteme externe reale.

04 Domeniul MVP și limitele asumate

Include acum	Nu include acum
CI românească model 1997: 1 imagine; certificat de înmatriculare RO: fețe/zone necesare în 1–2 imagini	Toate tipurile CEI/CIS, pașapoarte, documente din alte țări
JPG/PNG; PDF cu o singură pagină numai dacă implementarea permite	Scanare NFC, verificare document oficială, autentificare biometrică
Extragere automată + revizuire și corectare a câmpurilor	Decizie de subscriere, tarifare RCA/CASCO sau emitere poliță
Validări de format, normalizare, semnalare a incertitudinii	Verificare juridică a dreptului de proprietate ori a autenticității actului
JSON cu versiune, sursă, încredere și erori; export demonstrativ	Integrare de producție cu baze de date externe sau servicii ale asigurătorilor

05 User story și scenariul principal

Ca operator care pregătește o ofertă auto, vreau să trimit două fotografii de documente, să verific rapid datele recunoscute și să obțin un payload standardizat, pentru a nu le introduce manual în mai multe formulare.

1. Operatorul încarcă actul de identitate și certificatul de înmatriculare.
2. Interfața avertizează dacă fișierul este ilizibil, foarte mare sau de tip nesuportat.
3. Backend-ul procesează local imaginile: orientare, contrast, OCR, mapare câmpuri.
4. Validatorul verifică formatele și marchează câmpurile lipsă, conflictuale ori incerte.
5. Operatorul confirmă/corectează datele, explicit, în aceeași interfață.
6. Sistemul exportă JSON-ul confirmat și afișează un formular de ofertare precompletat.

06 Ecrane minime

Ecran	Conținut / comportament
Upload	Două zone de încărcare, tip document, preview și avertismente de calitate
Revizuire	Date grupate „Persoană” și „Vehicul”; marcaje: extras / lipsă / necesită verificare
Export	JSON lizibil + Copy/Download + formular demonstrativ precompletat

07 Modelul de date: câmpurile obligatorii pentru ofertare

Regula de bază: păstrează separat documentul-sursă, datele normalizate și eventualele corecturi. Un câmp absent se exprimă ca null, nu se inventează.

Document	Câmpuri MVP	Note importante
CI clasică	Nume, prenume, CNP dacă justificat, serie/număr act, expirare, adresă dacă e vizibilă	CNP cu acces restrâns și fără logare; data nașterii nu se deduce obligatoriu din CNP
Talon	A – nr. înmatriculare; B – prima înmatriculare; D.1/D.3 – marcă/model; E – VIN; P.1 – cm³; P.2 – kW; P.3 – combustibil	Păstrează separat titularul (C.1) de proprietar (C.2); nu presupune că sunt identici
Metadate	Tip document, scor de încredere pe câmp, cod sursă, stare verificare, versiune schemă	Scorul indică incertitudine tehnică, nu autenticitatea actului

08 Exemplu de JSON de ieșire (date integral fictive)


```
{
 "schema_version": "1.0.0",
 "processing_id": "demo-0001",
 "status": "needs_review",
 "purpose": "insurance_quote_prefill",
 "person": {
  "first_name": "ALEX", "last_name": "IONESCU",
  "national_id": null,
  "identity_document": {"type": "CI_1997", "series": "XY", "number": "000000"},
  "address": null
 },
 "vehicle": {
  "registration_number": "B99XYZ", "vin": "UU1AAAAAAAAAAAAAA",
  "make": "DACIA", "model": "LOGAN", "engine_cc": 999,
  "power_kw": 67, "fuel": "PETROL", "first_registration": "2020-03-10",
  "certificate_holder": {"name": "IONESCU ALEX"},
  "legal_owner": null
 },
 "field_meta": {
  "vehicle.vin": {"source": "registration.E", "confidence": 0.96,
                  "review_required": false},
  "person.address": {"source": null, "confidence": null,
                     "review_required": true}
 },
 "validation": {"passed": false,
  "issues": [{"field": "person.address", "code": "MISSING_VALUE"}]},
 "confirmed_by_operator": false
}
```


La confirmare, status devine "confirmed" și câmpurile corectate sunt exportate; operația nu dovedește identitatea persoanei și nu verifică oficial datele.

09 Arhitectură propusă: simplă, explicabilă, extensibilă

Strat	Tehnologie recomandată	Responsabilitate
Interfață	React + Vite (sau HTML simplu)	Upload, preview, formular de revizuire, export
API	Python FastAPI	Validare fișiere, orchestrat pipeline, schema JSON
Preprocesare	OpenCV / Pillow	Rotire, redimensionare, decupare, îmbunătățire contrast
OCR	Tesseract ron+eng; PaddleOCR opțional	Transformare imagine → text cu coordonate / scoruri unde sunt disponibile
Parser & validator	Reguli pe layout/coduri + regex + Pydantic	Extracție câmpuri, normalizare, validare VIN/date
Persistență	În memorie / fișiere temporare locale	Fără stocare permanentă a actelor în demo

Principiu arhitectural

Separă OCR-ul de parser. Motorul OCR poate fi înlocuit fără a schimba schema JSON sau integrarea cu sistemele de asigurări.

10 Pipeline de procesare

UPLOAD → verificare fișier → preprocesare → OCR → detecție tip/zonă → extragere structurată → validări → revizuire operator → export JSON / mapping pentru ofertare.

11 Contract API minimal

```
POST /api/v1/extract
Content-Type: multipart/form-data
Files: identity_image, registration_image
Response 200: { processing_id, status, person, vehicle,
                field_meta, validation, schema_version }

POST /api/v1/confirm
Content-Type: application/json
Body: { processing_id, corrected_person, corrected_vehicle }
Response 200: { status: "confirmed", payload: <JSON normalizat> }

Erori: 400 (tip invalid), 413 (fișier prea mare),
422 (document neidentificabil), 500 (eroare procesare).
```

Pentru un demo local este suficientă implementarea sincronă. În producție, sarcinile lungi vor trece într-o coadă, cu idempotency key, timeout și politici de retry.

12 Validare, incertitudine și tratarea erorilor

Regulă	Comportament MVP
VIN: exact 17 caractere, fără I/O/Q	Dacă nu respectă forma, marchează eroare; nu corecta automat O → 0 fără confirmare
Număr înmatriculare	Trim și uppercase; regex flexibil pentru RO; nu respinge forme istorice fără avertisment
Date calendaristice	Conversie în YYYY-MM-DD; nu interpreta liber un șir ambiguu
Cilindree și putere	Numere > 0 când prezente; păstrează unitățile cm^3 și kW
Titular ≠ proprietar	Două câmpuri distincte; nu folosi C.1 ca substitut automat pentru C.2
Încredere OCR	Prag configurabil (de ex. 0,85); sub prag cere revizuire
Câmp lipsă / act nou	null + motiv; operatorul poate introduce manual dacă este necesar
Foto cu reflexie / blur	Avertisment, solicită refotografiere; nu livra un „succes” fals

13 Confidențialitate, securitate și limite legale

- Prelucrarea se face numai pentru un scop declarat; se stabilește un temei juridic adecvat și o informare clară înaintea folosirii în producție (GDPR art. 5 și 6).
- Minimizarea: nu extrage, nu expune și nu păstra câmpuri inutile; CNP se tratează cu protecții suplimentare și doar dacă fluxul justifică necesitatea lui.
- Demo-ul folosește exclusiv documente sintetice / date fictive. Nu încărca actele reale ale unor terți în servicii AI publice.
- Fără imagini în loguri; mascarea datelor în erori; limite de dimensiune și tip; TLS și control acces obligatorii înainte de producție.
- Fișierele temporare se șterg la încheierea procesării; retenția în producție va fi definită în baza scopului și obligațiilor aplicabile, nu arbitrar.
- OCR nu înseamnă autentificare de identitate, detecție certă a falsurilor, acces la cipul CEI sau verificare în registrul autorităților.

14 Particularitate importantă: noile acte de identitate

În România există CI model 1997, carte electronică de identitate (CEI) și carte de identitate simplă (CIS). CEI nu afișează domiciliul tipărit: fotografierea actului nu poate furniza această adresă. Pentru un flux viitor CEI este necesar fie un canal autorizat de citire a datelor, fie completare separată, în acord cu scopul procesării. Nu promite „adresă extrasă din CEI” prin OCR.

15 Testare și criterii de acceptare

Țintele de mai jos sunt criterii propuse, nu rezultate deja obținute. Evaluează pe un set de test cu date fictive, imagini de calitate variabilă și etichete de referință.

Metrică / test	Țintă pentru MVP
Demo end-to-end	2 documente → revizuire → confirmare → JSON utilizabil, fără intervenție în cod
Completitudine payload	Toate cheile contractului prezente; lipsurile sunt null, nu valori fabricate
Corectitudine câmpuri critice	Țintă ≥ 90% pe câmpuri critice înainte de corectare, pe un set controlat; măsoară separat rezultatul după corectare
Validări	100% cazuri VIN cu lungime greșită semnalate în testele unitare
Erori utilizator	Fișiere invalide și imagini inutilizabile au mesaje clare
Timp de procesare	Țintă demonstrativă < 10 sec/document pe laptopul folosit; măsoară, nu afirma fără test
Confidențialitate demo	Zero documente reale; fără fișiere sau CNP în logurile demonstrative

16 Plan practic pentru o singură seară

Prioritate	Livrabil	Criteriu „gata”
P0 — obligatoriu	Upload + OCR pentru cele 2 tipuri + extragere câmpuri de bază	Demo pe 2–3 fișiere sintetice cunoscute
P0 — obligatoriu	Validare + formular corectabil + JSON download/copy	Modificarea unui câmp apare în JSON final
P1 — dacă rămâne timp	Formular RCA demonstrativ precompletat	Arată utilizarea datelor, fără calcul real
P1 — dacă rămâne timp	5 teste automate pentru parser / validatori	Acoperă VIN, date, număr, lipsuri și normalizare
P2 — ulterior	CEI/CIS, autentificare, batch, plugin CRM, istoric	Roadmap, nu funcționalități pretinse

Ordinea corectă de implementare

Începe cu un JSON final valid și un formular de revizuire. Abia apoi îmbunătățește OCR-ul. Fără corectare manuală, o singură eroare de VIN poate compromite demonstrația.

17 Alte documente: ce merită adăugat și în ce ordine

Prioritate	Document	Utilizare de business	Verdict
1	Cartea de identitate a vehiculului (CIV)	Date tehnice suplimentare utile pentru descrierea / evaluarea auto	Extensie naturală după talon; nu în seara aceasta
2	Poliță RCA existentă	Reînnoire: precompletare, comparație și identificare date de contract	Valoare foarte bună pentru retenție
3	Permis de conducere	Date ale conducătorului unde fluxul le cere	Util în scenarii specifice; nu universal necesar
4	Constatare amiabilă / documente de daună	Preluare date pentru deschiderea dosarului de daună	Impact mare, complexitate OCR/layout ridicată
5	Pașaport / permis de ședere	Identificarea clienților fără CI românească	Extinde acoperirea, dar necesită validări noi
6	Documente pentru asigurarea locuinței	Adresă, suprafață, tip proprietate din documente relevante	Produs nou, cu layout-uri și riscuri diferite

18 Roadmap după MVP

Etapa 1 (funcționalitate): CEI/CIS, detectare automată tip document, suport PDF multipagină, reguli de layout multiple. Etapa 2 (integrare): schema de adaptor pe asigurător, API keys, audit trail, control acces și retenție. Etapa 3 (automatizare): precompletare de formulare reale, procesare batch, verificări de consistență între documente și analitice de economie de timp.

19 Riscuri și compromisuri explicite

- Risc major: prea multe tipuri de documente → fiecare nou layout crește costul testării; acceptă doar două în MVP.
- Risc major: scorul OCR poate fi înșelător → verificările deterministe și operatorul decid confirmarea finală.
- Risc major: lipsa datasetului legal → exemple sintetice, fără afirmații despre acuratețe în producție.
- Risc de produs: JSON-ul brut nu arată valoarea → demonstrează precompletarea unui formular de ofertare.
- Risc de integrare: asigurătorii pot cere structuri diferite → model intern stabil + mapping separat.

20 Script de demo (aprox. 90–120 secunde)

„Un operator primește fotografii cu actul de identitate și talonul. În loc să transcrie manual datele, le încarcă aici. Sistemul identifică datele de persoană și vehicul, le normalizează și semnalează valorile incerte. Corectez intenționat un câmp, confirm și export JSON-ul. Același payload precompletează un formular de ofertare demonstrativ. Nu pretindem că înlocuim validarea oficială; eliminăm munca repetitivă și oferim control asupra calității datelor.”

21 Decizii tehnice de înghețat înainte de implementare

Întrebare	Decizie recomandată
Care sunt documentele demonstrabile?	CI model 1997 + talon RO, cu imagini de test pregătite
Cum tratăm noile CEI?	Descriem în roadmap, fără a promite domiciliu din fotografie
Ce câmpuri sunt critice?	Nume, prenume, număr înmatriculare, VIN, marcă, model, cilindree
Ce se întâmplă dacă OCR greșește?	Review obligatoriu, editabil, înainte de export
Cum arătăm impactul?	Formular de ofertare demonstrativ + cronometrare manual vs. asistat
Ce păstrăm?	Date doar în sesiunea demo; fără documente reale ori loguri sensibile
Ce înseamnă finalizat?	Flux complet demonstrat fără modificarea codului în timpul prezentării

22 Referințe tehnice și de reglementare

• MAI — documentație publică pentru cartea electronică de identitate: carteadeidentitate.gov.ro/despre/ și /utile/

• Portal Legislativ — Ordinul nr. 1.454/2006 privind certificatul de înmatriculare, modificat prin Ordinul nr. 189/2023

• Regulamentul (UE) 2016/679 (GDPR), în special art. 5, 6 și 32

Aceste referințe sunt folosite pentru proiectarea câmpurilor și a constrângerilor. Documentul este o propunere tehnică; înaintea folosirii în producție este necesară validarea juridică și de securitate.

Concluzie de produs

Propoziție de valoare pentru finală

AsigParse OCR transformă două documente într-un set coerent și verificabil de date pentru ofertare, cu posibilitatea de integrare în orice sistem printr-un JSON standardizat.